Український Католицький Університет

Курс «Штучний інтелект» · Семестровий проєкт · 2026

Трекінг об’єктів на відео з використанням world models

Дослідження потенціалу попередньо натренованої world model для стійкого трекінгу об’єктів в умовах оклюзії

Команда:

Гаманюк Марія

Говоров Андрій

Лейко Нестор

Ментор:

Сумик Марта

Репозиторій:

https://github.com/MariiaHamanuk/Object-Tracking

Пропозиція проєкту, подана в межах курсу «Штучний інтелект»

Факультет прикладних наук

2026-09-16

1. Проблема та мотивація

Трекери об’єктів (OSTrack, STARK) визначають положення цілі, порівнюючи шаблон із поточним кадром. Під час тривалих оклюзій вони втрачають візуальну інформацію про об’єкт, а після його появи можуть втратити або переплутати ціль. Людина ж здатна передбачати рух прихованого об’єкта, спираючись на розуміння фізичних закономірностей. Наразі актуальною є перевірка гіпотези, чи допоможе інтеграція попередньо натренованої world model (наприклад V-JEPA 2), підвищити стійкість трекінгу до оклюзій. Це дасть змогу оцінити застосовність таких моделей у трекінгу та їхню потенційну користь для відеоспостереження, автономного водіння й робототехніки, де тривалі оклюзії є типовою проблемою.

2. Огляд джерел та наявних рішень

У роботі [1] запропоновано концепцію world model, яка формує внутрішнє представлення стану середовища та використовує його для прогнозування майбутніх станів.

У V-JEPA [2] запропоновано навчання візуальних представлень відео шляхом прогнозування прихованих представлень замість безпосереднього відновлення пікселів. Це дозволяє моделі враховувати просторову та часову інформацію з відео.

V-JEPA 2 [3] розвиває цей підхід у напрямку world model, здатної моделювати та прогнозувати майбутні стани фізичного середовища. Попередньо натреновані моделі V-JEPA 2 можуть бути використані разом із готовим трекером (OSTrack або STARK) для перевірки їхнього впливу на якість трекінгу.

Tokmakov та співавтори [4] запропонували модель трекінгу з просторово-часовою пам’яттю, яка зберігає інформацію про об’єкти та дозволяє прогнозувати їхнє положення під час оклюзії. Цей підхід може бути використаний як окремий метод для порівняння з класичним трекером та підходом на основі V-JEPA 2.

У роботі TCOW [5] досліджується відстеження об’єктів під час складних оклюзій, зокрема при перекритті іншими об’єктами або контейнерами. Запропоновані методи оцінювання можуть бути використані для перевірки роботи нашої системи в умовах оклюзії.

3. Дані

Основним джерелом даних є LaSOT (Large-scale Single Object Tracking) [6]: 1 400 відео (близько 3,87 млн кадрів) у 85 категоріях об’єктів із ручною покадровою розміткою обмежувальних рамок і прапорцями повного перекриття та виходу за межі кадру. Це один із небагатьох бенчмарків довготривалого відстеження одиночного об’єкта: середня довжина відео близько 2 500 кадрів (83 секунди). Кожне відео має текстовий опис, який не використовуємо, оскільки відстеження суто візуальне.

Офіційний поділ: 1 120 тренувальних і 280 тестових відео в базових 70 категоріях (по 16 і 4 на категорію відповідно); розширення у 150 відео в 15 нових категоріях, переважно для перевірки узагальнення на категорії поза навчальними. Через обмеження часу й обчислювальних ресурсів навчатимемо модель на меншій підмножині зі збереженням балансу класів, а оцінюватимемо на всіх 280 офіційних тестових відео для порівнянності з опублікованими результатами. LaSOT безкоштовний для особистого, академічного та освітнього використання.

4. Підхід і методи

За baseline буде відтворено готовий трекер OSTrack або STARK. Для інтеграції world model планується використати попередньо натренований V-JEPA 2 Encoder, який отримує послідовність відеокадрів і формує просторово-часові представлення відео. Ці представлення будуть використані трекером як додаткова інформація про стан та рух об’єкта.

Основна ідея полягає в тому, щоб поєднати локальну візуальну інформацію від трекера з часовим

контекстом, отриманим від V-JEPA 2. Особливу увагу буде приділено використанню представлень попередніх кадрів для підтримки треку, коли ціль частково або повністю зникає за оклюзією (з розбивкою сценаріїв оклюзії).

Планується дослідити інтеграцію V-JEPA 2 на рівні ознак (feature-level fusion), не змінюючи основну архітектуру baseline-трекера.

5. Оцінювання результатів

Як baseline буде використано трекер OSTrack або STARK без додаткової інформації від world model. Запропонований підхід буде порівнюватися з ним за якістю відстеження об'єктів у звичайних умовах та під час оклюзії.

Для оцінювання буде використано стандартні для SOT метрики - Success (AUC), Precision, Normalized Precision (як у OSTrack/STARK), а також власну метрику *occlusion recovery rate*: частку випадків коректного повернення на ціль для перевірки гіпотези проєкту.

Окремо буде проаналізовано залежність якості трекінгу від тривалості оклюзії, щоб визначити, чи використання попередньо натренованої world model допомагає зберігати правильний трек об'єкта під час його тимчасового зникнення.

6. План і ризики

> **Ключові цифри:** 1400 відео LaSOT (280 у test split) · 2 конфігурації моделі (baseline-трекер vs. baseline + V-JEPA 2) · 6 тижнів до midterm

До midterm (6 тижнів): відтворення baseline (OSTrack/STARK) на LaSOT, реалізація першої інтеграції V-JEPA 2 в pipeline трекера, перший прогін порівняння метрик на підвибірці відео з оклюзією.

До фінального захисту: друга конфігурація інтеграції, повна оцінка на LaSOT з розбивкою результатів за сценаріями оклюзії, дооформлення репозиторію та звіту, створення постеру.

Ризики:

- **Не справдиться першопочаткова гіпотеза**: Інтеграція V-JEPA 2 дає приріст якості трекінгу. План Б: спростити інтеграцію до окремого post-hoc модуля передбачення позиції лише на кадрах із втраченим треком, або перенести акцент аналізу на умови, за яких ефект усе ж спостерігається;
- **Недостатньо прикладів тривалої/повної оклюзії** в наявних відео для статистично значущого порівняння. План Б: доповнити тестову вибірку штучно згенерованими оклюзіями (програмне маскування ділянки кадру) поверх реальних відео LaSOT.
- **Нестача обчислювальних ресурсів навіть на офіційному test split** План Б: кешувати ембединги V-JEPA 2 один раз замість перерахунку при кожному експерименті; для розробки й дебагу - ще менша підвибірка (30–50 відео з найбільшою щільністю оклюзії), повний test split – лише для фінальних цифр.

7. Contribution statement

- **Гаманюк Марія** — 33%: дані й препроцесинг LaSOT (відбір за атрибутами оклюзії), дизайн і реалізація evaluation pipeline (метрики, розбивка за сценаріями оклюзії), співрозробка fusion-підходу
- **Говоров Андрій** — 33%: дизайн feature-level fusion (спосіб поєднання ознак V-JEPA 2 з трекером), аналіз результатів
- **Лейко Нестор** — 33%: інфраструктура й обчислення: відтворення baseline (OSTrack/STARK) та запуск V-JEPA 2 і навчання/інференсу, документація pipeline запуску

Список джерел

[1] David Ha and Jürgen Schmidhuber. World models. *arXiv preprint arXiv:1803.10122*, 2018.

[2] Adrien Bardes, Quentin Garrido, Jean Ponce, Xinlei Chen, Michael Rabbat, Yann LeCun, Mahmoud Assran, and Nicolas Ballas. Revisiting feature prediction for learning visual representations from video. *arXiv preprint arXiv:2404.08471*, 2024.

[3] Mido Assran, Adrien Bardes, David Fan, Quentin Garrido, Russell Howes, Mojtaba Komeili, Matthew Muckley, Ammar Rizvi, Claire Roberts, Koustuv Sinha, Artem Zholus, Sergio Arnaud, Abha Gejji, Ada Martin, Francois Robert Hogan, Daniel Dugas, Piotr Bojanowski, Vasil Khalidov, Patrick Labatut, Francisco Massa, Marc Szafraniec, Kapil Krishnakumar, Yong Li, Xiaodong Ma, Sarath Chandar, Franziska Meier, Yann LeCun, Michael Rabbat, and Nicolas Ballas. V-JEPA 2: Self-supervised video models enable understanding, prediction and planning. *arXiv preprint arXiv:2506.09985*, 2025.

[4] Pavel Tokmakov, Jie Li, Wolfram Burgard, and Adrien Gaidon. Learning to track with object permanence. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10860–10869, 2021.

[5] Basile Van Hoorick, Purva Tendulkar, Dídac Suris, Dennis Park, Simon Stent, and Carl Vondrick. Tracking through containers and occluders in the wild. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 13802–13812, 2023.

[6] Heng Fan, Haotian Bai, Liting Lin, Fan Yang, Peiyang Chu, Ge Deng, Sijia Yu, Mingzhen Huang, Juehuan Liu, Yong Xu, Chunyuan Liao, Lin Yuan, and Haibin Ling. LaSOT: A high-quality large-scale single object tracking benchmark. *International Journal of Computer Vision*, 129:439–461, 2021.